# Prévision du nombre de logements individuels autorisés en France

**Techniques de prévision et conjoncture**

DAGBO Élisée

## Table des matières

**1 Packages et données** **2**

**2 Analyse exploratoire** **2**
2.1 Présentation de la série . . . . . 2
2.2 Points atypiques (tsoutliers) . . . . . 4
2.3 Statistiques descriptives de la série corrigée . . . . . 5
2.4 Saisonnalité . . . . . 7
2.5 Désaisonnalisation X13-ARIMA-SEATS (RJDemetra) . . . . . 8

**3 Prévision à un an (2020)** **10**
3.1 Naïve saisonnière, X13, STL, STS . . . . . 10
3.2 Lissage exponentiel . . . . . 11
3.3 SARIMA et SSARIMA . . . . . 11

**4 Comparaison graphique des prévisions** **12**

**5 Qualité de prévision : MSE et $R^2OOS$** **14**

**6 Test de Diebold-Mariano contre un AR(1)** **16**

**7 Vérification sur la série brute (non corrigée)** **16**

**8 Conclusion** **17**

# 1 Packages et données

```
library(readr)
library(tsoutliers)
library(forecast)
library(smooth)      # auto.adam, auto.ssarima
library(TSA)         # periodogram
library(moments)
library(fBasics)
library(ggplot2)
library(RJDemetra)   # nécessite Java
library(tidyr)
library(dplyr)
library(purrr)
library(tibble)
library(seastests)
```

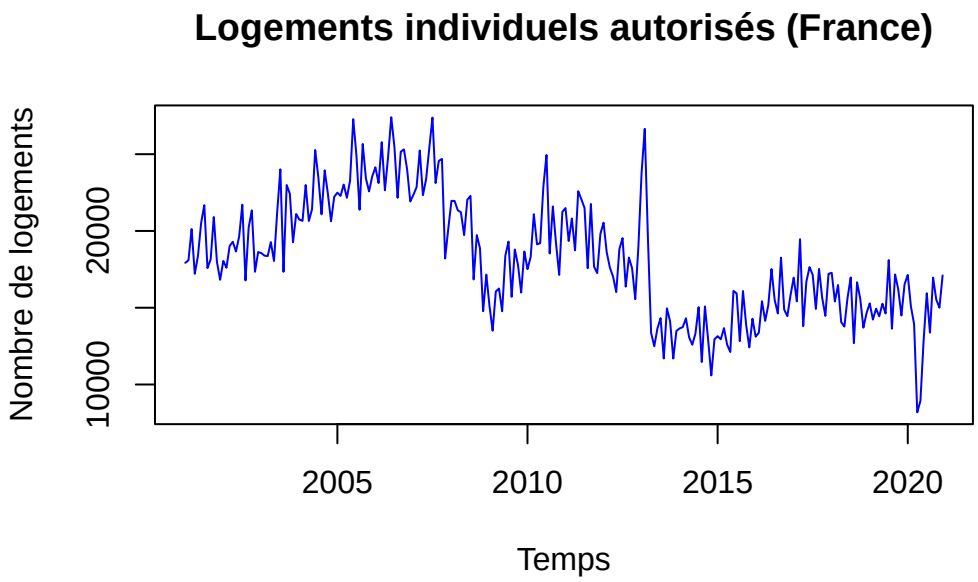
Source : INSEE, nombre de logements individuels autorisés à la construction en France (hors Mayotte), mensuel, janvier 2001 à décembre 2020 (240 observations).

```
y <- read_delim("data/valeurs_mensuellesS.csv", delim = ";",
                escape_double = FALSE, trim_ws = TRUE)
yy <- ts(y$Nbr_const_ind_aut, start = c(2001, 1), frequency = 12)
```

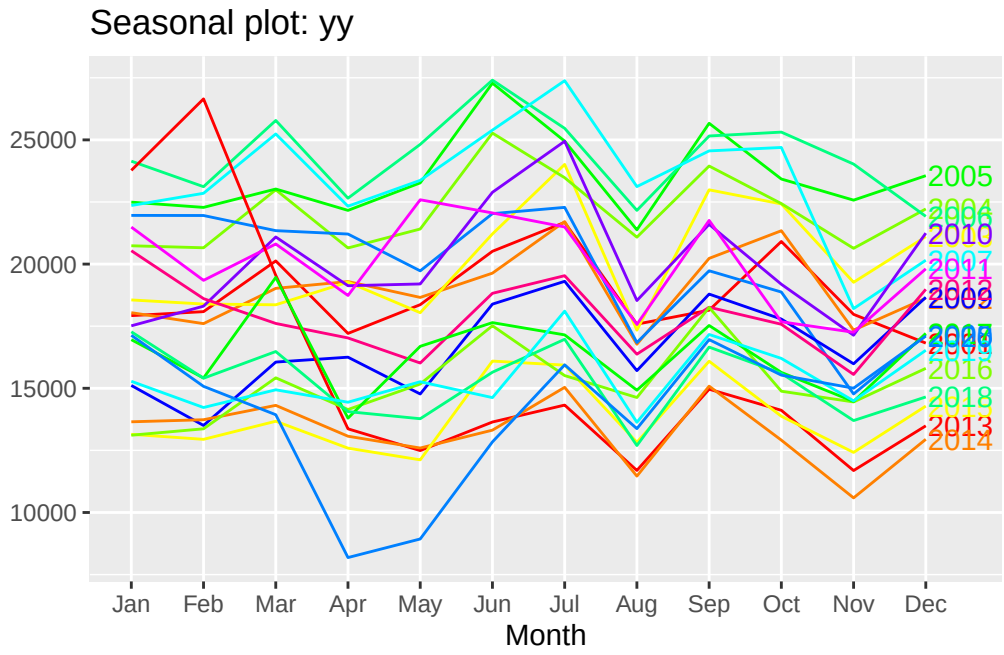
# 2 Analyse exploratoire

## 2.1 Présentation de la série

```
plot.ts(yy, main = "Logements individuels autorisés (France)",
        ylab = "Nombre de logements", xlab = "Temps", col = "blue")
```




```
ggseasonplot(yy, col = rainbow(12), year.labels = TRUE)
```

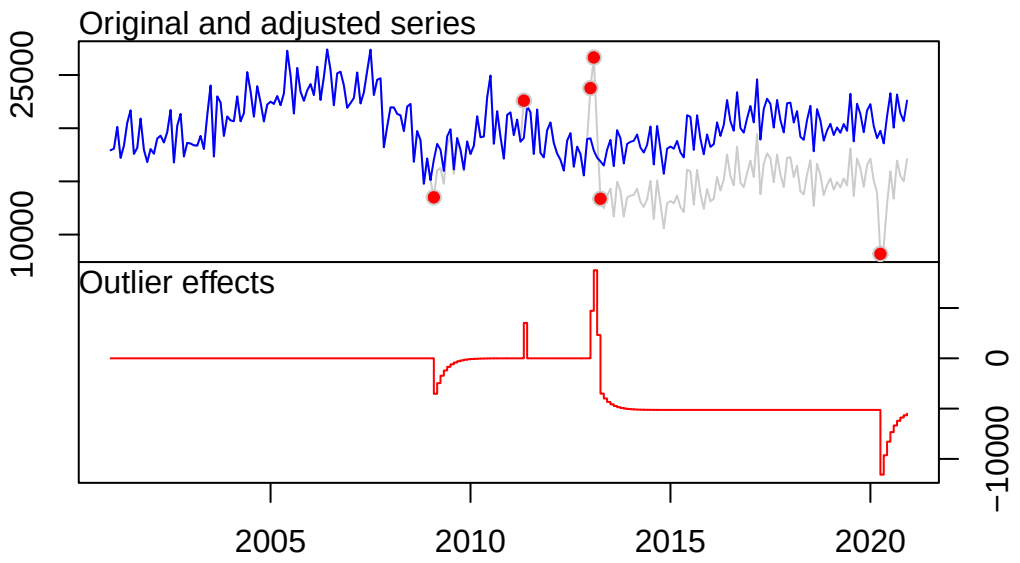



La série baisse à long terme (maximum entre 2005 et 2007, creux entre 2013 et 2015, chute

en avril 2020) et présente une forte saisonnalité : hausse en juillet, creux en août, rebond en septembre.

### 2.2 Points atypiques (tsoutliers)

```
fit <- tso(yy)
plot(fit)
```




```
fit$outliers
```

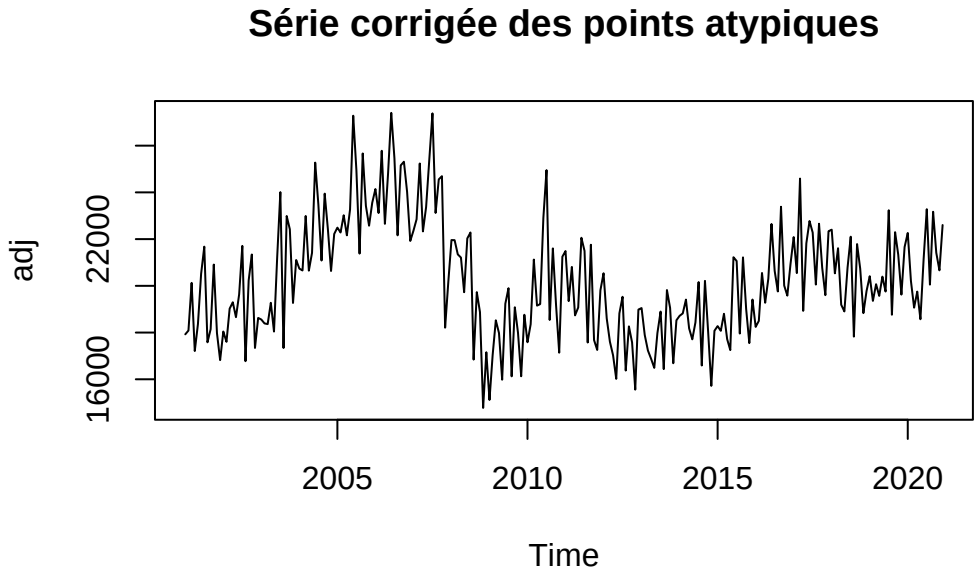
```
  type ind    time   coefhat     tstat
1   TC  98 2009:02 -3527.310 -3.844420
2   AO 125 2011:05  3518.053  4.142624
3   TC 145 2013:01  4723.981  4.311244
4   AO 146 2013:02  5449.097  5.885601
5   LS 148 2013:04 -5130.033 -6.213229
6   TC 232 2020:04 -6436.517 -5.509643
```

Les points détectés (méthode de Chen et Liu, 1993) sont : TC en 2009 :02, AO en 2011 :05, TC en 2013 :01, AO en 2013 :02, LS en 2013 :04 et TC en 2020 :04. Les trois plus forts (|t-stat|) sont :

— **LS 2013 :04 et AO 2013 :02** : entrée en vigueur obligatoire de la RT 2012 au 1er janvier 2013. Les dépôts se sont concentrés fin 2012 (pic ponctuel en février 2013), puis le niveau a durablement baissé.
— **TC 2020 :04** : premier confinement lié au COVID-19, services d'urbanisme fermés ou au ralenti, choc temporaire.

Ces explications sont des hypothèses économiques plausibles, non testées ici.

```
adj <- fit$yadj   # série corrigée des points atypiques
plot(adj, main = "Série corrigée des points atypiques")
```



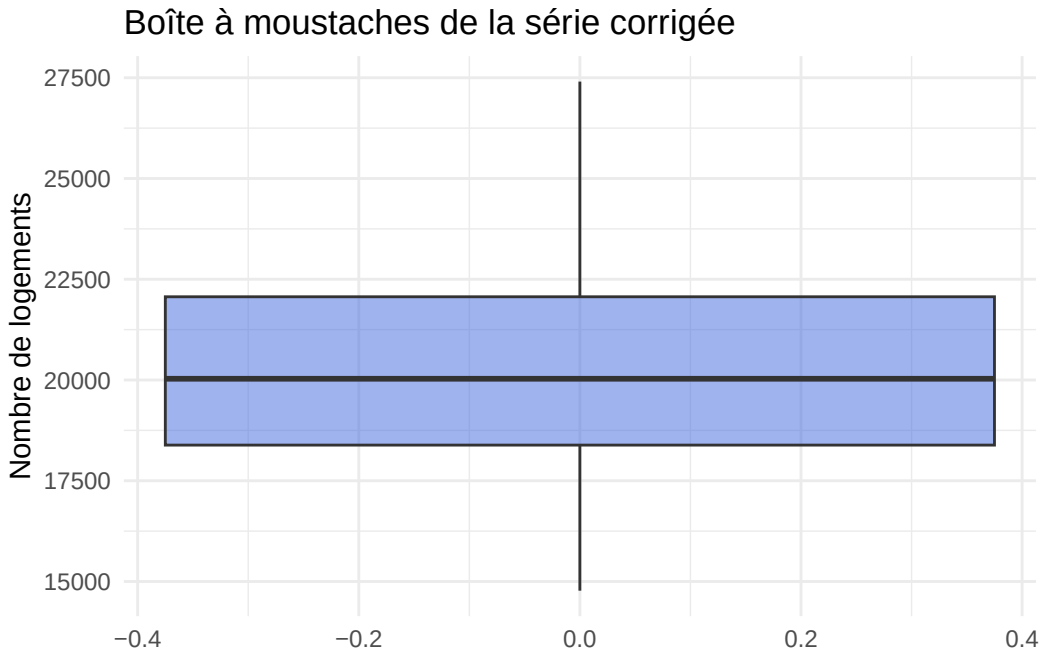

**Remarque.** La détection des points atypiques est faite sur toute la période, 2020 comprise, donc la série corrigée `adj` ne contient plus le choc d'avril 2020. C'est cette série qui sert de cible dans la partie prévision (comme demandé par l'énoncé) ; une vérification sur la série brute est faite à la fin.

### 2.3 Statistiques descriptives de la série corrigée

```
basicStats(adj)
```

```
                    adj
nobs          2.400000e+02
NAs           0.000000e+00
Minimum       1.477200e+04
Maximum       2.740500e+04
1. Quartile   1.838475e+04
3. Quartile   2.206538e+04
Mean          2.026838e+04
Median        2.003124e+04
Sum           4.864411e+06
SE Mean       1.609018e+02
LCL Mean      1.995141e+04
UCL Mean      2.058535e+04
Variance      6.213456e+06
Stdev         2.492681e+03
Skewness      4.179800e-01
Kurtosis     -2.221670e-01
```

```r
ggplot(tibble(valeur = as.numeric(adj)), aes(y = valeur)) +
  geom_boxplot(fill = "royalblue", alpha = 0.5) +
  labs(title = "Boîte à moustaches de la série corrigée", y = "Nombre de logements") +
  theme_minimal()
```



## 2.4 Saisonnalité

```
combined_test(adj)      # test de Webel-Ollech
```

```
Test used:  WO

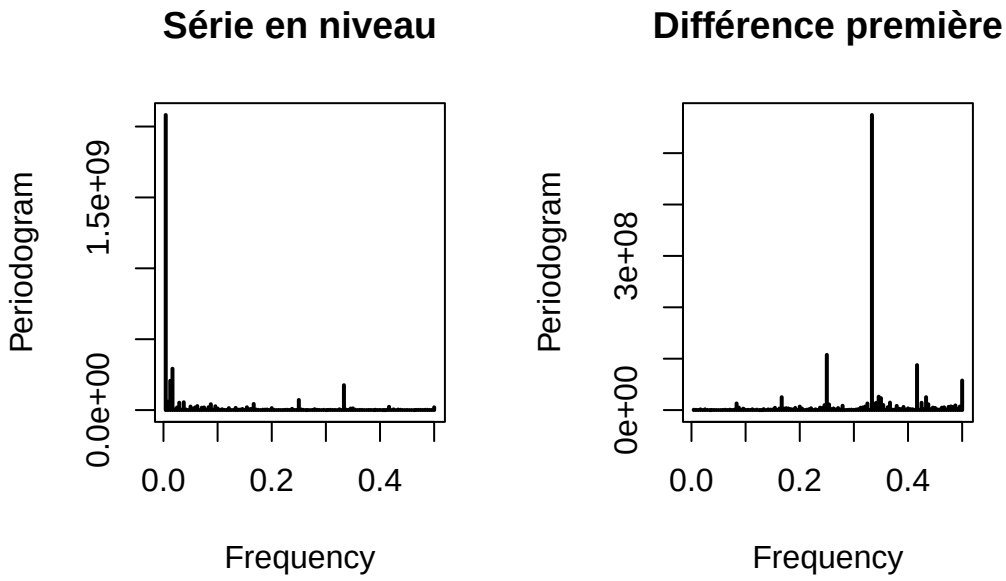
Test statistic:  1
P-value:  0 0 0
```

```
seasdum(adj)            # variables dichotomiques saisonnières
```

```
Test used:  SeasonalDummies

Test statistic:  34.22
P-value:  0
```

```
dadj <- diff(adj, differences = 1)
par(mfrow = c(1, 2))
periodogram(yy,   main = "Série en niveau")
periodogram(dadj, main = "Différence première")
```



```r
par(mfrow = c(1, 1))
```

### 2.5 Désaisonnalisation X13-ARIMA-SEATS (RJDemetra)

```r
myspec  <- x13_spec("RSA5c")
mysax13 <- x13(adj, myspec)
summary(mysax13$regarima)
```

```
y = regression model + arima (0, 1, 1, 1, 1, 1)

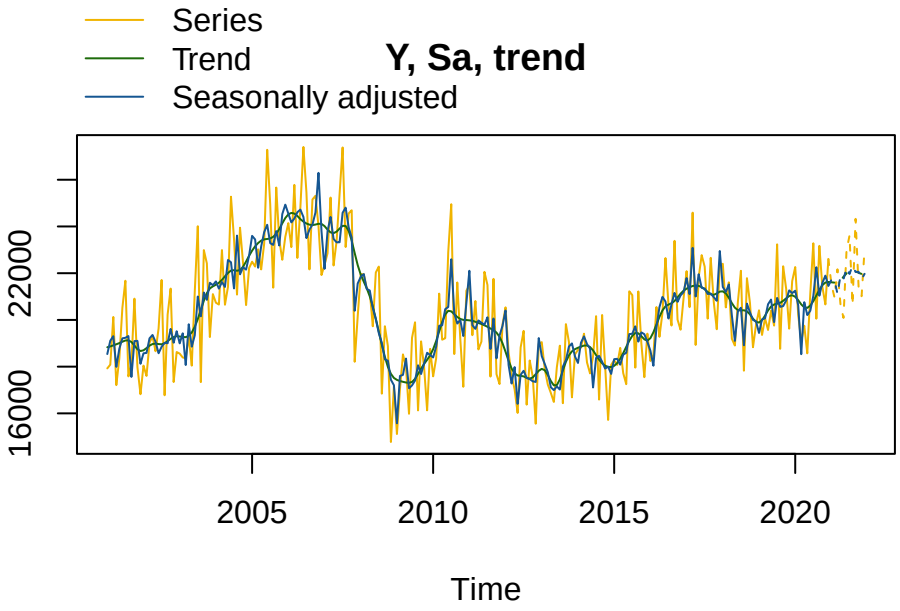
Model: RegARIMA - X13
Estimation span: from 1-2001 to 12-2020
Log-transformation: yes
Regression model: no mean, trading days effect(6), no leap year effect, Easter effect, no ou

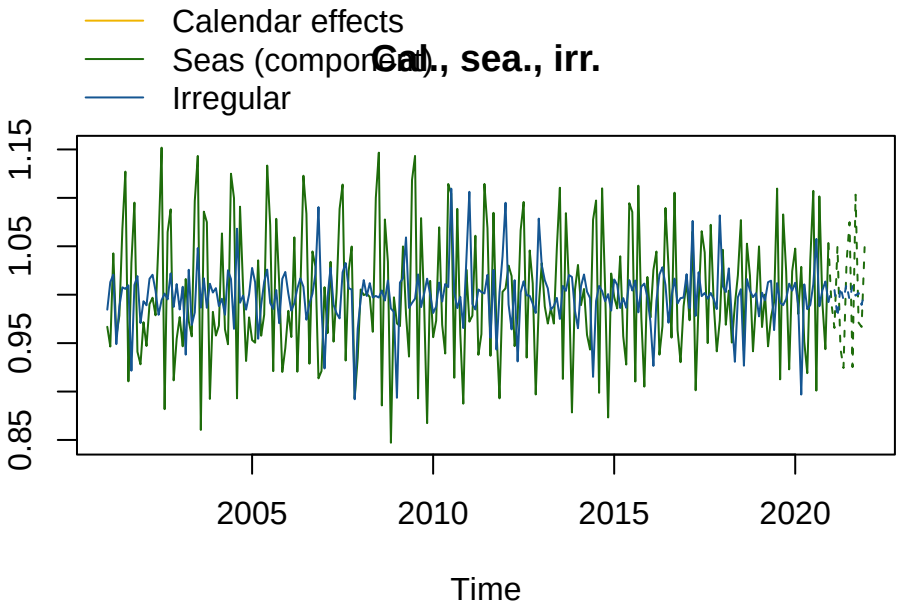
Coefficients:
ARIMA:
          Estimate Std. Error  T-stat Pr(>|t|)
BPhi(1)   -0.26015    0.08631  -3.014  0.00287 **
Theta(1)  -0.46271    0.06074  -7.618 6.91e-13 ***
BTheta(1) -0.84805    0.05729 -14.802  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Regression model:
             Estimate Std. Error T-stat Pr(>|t|)
Monday      0.0100099  0.0059079  1.694 0.091574 .
Tuesday     0.0053681  0.0059266  0.906 0.366023
Wednesday   0.0104593  0.0059345  1.762 0.079338 .
Thursday    0.0087959  0.0059974  1.467 0.143863
Friday      0.0004908  0.0060190  0.082 0.935079
Saturday   -0.0205703  0.0058344 -3.526 0.000511 ***
Easter [1] -0.0237688  0.0112117 -2.120 0.035092 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 0.05001 on 216 degrees of freedom
Log likelihood = 352.7, aic =  3817, aicc =  3819, bic(corrected for length) = -5.752
```

```
plot(mysax13)
```




La procédure retient une décomposition multiplicative (transformation logarithmique), un RegARIMA(0,1,1)(1,1,1)12 et des effets de calendrier (samedi, lundi, mercredi, Pâques).

# 3 Prévision à un an (2020)

Les modèles sont **tous estimés sur la période d'apprentissage janvier 2001 à décembre 2019**, puis comparés sur 2020.

```
train <- window(adj, start = c(2001, 1), end = c(2019, 12))
test  <- window(adj, start = c(2020, 1), end = c(2020, 12))
h <- 12
```

## 3.1 Naïve saisonnière, X13, STL, STS

```
prev_snaive <- snaive(train, h = h)

myregx13_train <- regarima_x13(train, spec = "RG5c")
summary(myregx13_train)
```

```
y = regression model + arima (0, 1, 1, 1, 1, 1)

Model: RegARIMA - X13
Estimation span: from 1-2001 to 12-2019
Log-transformation: yes
Regression model: no mean, trading days effect(6), no leap year effect, Easter effect, no ou

Coefficients:
ARIMA:
          Estimate Std. Error  T-stat Pr(>|t|)
BPhi(1)   -0.24268    0.08697  -2.791  0.00574 **
Theta(1)  -0.45604    0.06288  -7.252  7.3e-12 ***
BTheta(1) -0.84848    0.05743 -14.774  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Regression model:
            Estimate Std. Error T-stat Pr(>|t|)
Monday      0.009199   0.006025  1.527 0.128234
Tuesday     0.009326   0.006132  1.521 0.129787
Wednesday   0.008165   0.006061  1.347 0.179383
Thursday    0.008647   0.006057  1.428 0.154856
Friday      0.001118   0.006113  0.183 0.854999
Saturday   -0.021397   0.005991 -3.571 0.000438 ***
```

```
Easter [1] -0.025279   0.011215 -2.254 0.025207 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 0.04948 on 204 degrees of freedom
Log likelihood = 335.9, aic =  3612, aicc =  3614, bic(corrected for length) = -5.762
```

```r
prev_x13 <- myregx13_train$forecast[1:h]

fitstl  <- stlm(train)
prevstl <- forecast(fitstl, h = h)

fitsts  <- StructTS(train)
prevsts <- forecast(fitsts, h = h)
```

### 3.2 Lissage exponentiel

```r
fithw   <- HoltWinters(train, seasonal = "mul")
prevhw  <- forecast(fithw, h = h)

fitets  <- ets(train)
prevets <- forecast(fitets, h = h)

fittbats  <- tbats(train)
prevtbats <- forecast(fittbats, h = h)

fitadam1  <- auto.adam(train, model = "MAdA", lags = c(1, 12), select = TRUE)
prevadam1 <- forecast(fitadam1, h = h)

fitadam2  <- auto.adam(train, model = "MAdA", lags = c(1, 12),
                       orders = list(ar = c(3, 3), i = c(2), ma = c(3, 3)),
                       select = TRUE)
prevadam2 <- forecast(fitadam2, h = h)
```

### 3.3 SARIMA et SSARIMA

```r
fitsarima  <- auto.arima(train)
prevsarima <- forecast(fitsarima, h = h, level = 0.90)

# CORRECTION : SSARIMA estimé sur `train` (et non sur toute la série `adj`)
fitssarima  <- auto.ssarima(train, lags = c(1, 12),
                            orders = list(ar = c(3, 3), i = c(2), ma = c(3, 3)),
                            select = TRUE)
prevssarima <- forecast(fitssarima, h = h, level = 0.90)
```

## 4 Comparaison graphique des prévisions

```r
dates <- seq(as.Date("2020-01-01"), by = "month", length.out = h)
obs   <- as.numeric(test)

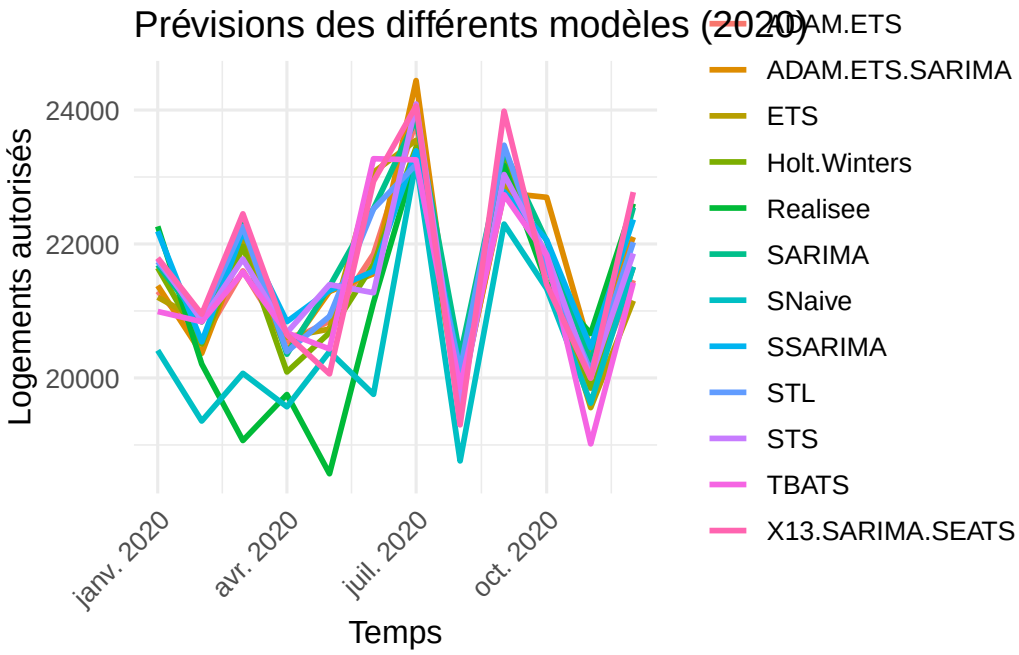
df_forecasts <- data.frame(
  Date = dates,
  SNaive = as.numeric(prev_snaive$mean),
  X13.SARIMA.SEATS = as.numeric(prev_x13),
  STL = as.numeric(prevstl$mean),
  STS = as.numeric(prevsts$mean),
  Holt.Winters = as.numeric(prevhw$mean),
  ETS = as.numeric(prevets$mean),
  TBATS = as.numeric(prevtbats$mean),
  ADAM.ETS = as.numeric(prevadam1$mean),
  ADAM.ETS.SARIMA = as.numeric(prevadam2$mean),
  SARIMA = as.numeric(prevsarima$mean),
  SSARIMA = as.numeric(prevssarima$mean),
  Realisee = obs
)

# contrôle de cohérence : toutes les prévisions ont 12 valeurs, dans l'échelle de la série
stopifnot(nrow(df_forecasts) == 12)
summary(df_forecasts[, -1])
```

```
     SNaive       X13.SARIMA.SEATS      STL             STS
 Min.   :18761   Min.   :19300    Min.   :20100   Min.   :19572
 1st Qu.:19610   1st Qu.:20499    1st Qu.:20775   1st Qu.:20810
 Median :20231   Median :21593    Median :21700   Median :21585
```

```
 Mean   :20539   Mean   :21695    Mean   :21608   Mean   :21513
 3rd Qu.:21415   3rd Qu.:22815    3rd Qu.:22326   3rd Qu.:21846
 Max.   :23236   Max.   :24059    Max.   :23475   Max.   :24090
  Holt.Winters         ETS             TBATS          ADAM.ETS
 Min.   :19552   Min.   :19556   Min.   :19016   Min.   :19660
 1st Qu.:20402   1st Qu.:20700   1st Qu.:20613   1st Qu.:20544
 Median :21651   Median :21180   Median :21207   Median :21378
 Mean   :21342   Mean   :21426   Mean   :21326   Mean   :21346
 3rd Qu.:21772   3rd Qu.:22265   3rd Qu.:22053   3rd Qu.:21853
 Max.   :23442   Max.   :23547   Max.   :23273   Max.   :23831
 ADAM.ETS.SARIMA     SARIMA          SSARIMA         Realisee
 Min.   :19703   Min.   :20237   Min.   :20114   Min.   :18570
 1st Qu.:20410   1st Qu.:20717   1st Qu.:20765   1st Qu.:19976
 Median :21467   Median :21866   Median :21826   Median :20895
 Mean   :21590   Mean   :21795   Mean   :21652   Mean   :21014
 3rd Qu.:22253   3rd Qu.:22533   3rd Qu.:22234   3rd Qu.:22348
 Max.   :24440   Max.   :23869   Max.   :23391   Max.   :23282
```

```r
df_long <- pivot_longer(df_forecasts, -Date, names_to = "Methode", values_to = "Valeur")
ggplot(df_long, aes(Date, Valeur, color = Methode)) +
  geom_line(linewidth = 1) +
  labs(title = "Prévisions des différents modèles (2020)", x = "Temps",
       y = "Logements autorisés") +
  theme_minimal(base_size = 12) +
  theme(legend.title = element_blank(), axis.text.x = element_text(angle = 45, hjust = 1))
```




## 5 Qualité de prévision : MSE et $R^2$OOS

Le $R^2$OOS compare chaque modèle à la prévision naïve saisonnière : $R^2\text{OOS} = 1 - \text{MSE}_{\text{modèle}} / \text{MSE}_{\text{naïf}}$. Une valeur positive signifie que le modèle fait mieux que le naïf.

```
previsions <- df_forecasts |> select(-Date, -Realisee)
mse_naive  <- mean((obs - previsions$SNaive)^2)

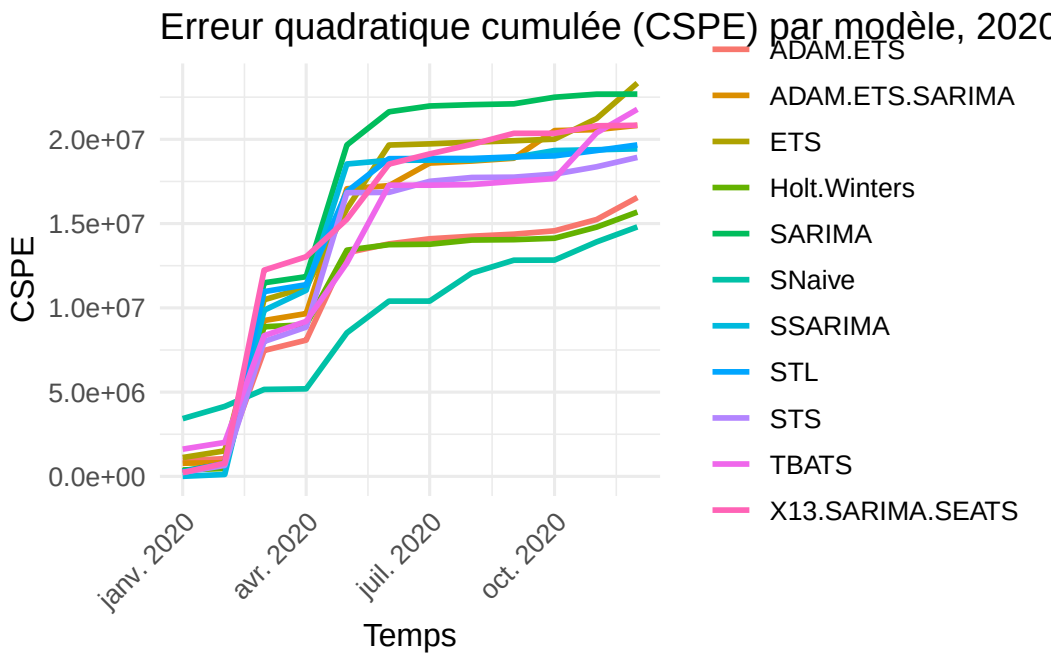
results <- tibble(Modele = names(previsions),
                  MSE = map_dbl(previsions, ~ mean((obs - .x)^2))) |>
  mutate(R2OOS = ifelse(Modele == "SNaive", NA, 1 - MSE / mse_naive)) |>
  arrange(MSE)
results
```

```
# A tibble: 11 x 3
   Modele                MSE   R2OOS
   <chr>               <dbl>   <dbl>
 1 SNaive           1233516. NA
 2 Holt.Winters     1307014. -0.0596
 3 ADAM.ETS         1378820. -0.118
 4 STS              1577125. -0.279
```

```
 5 SSARIMA           1619605. -0.313
 6 STL               1638873. -0.329
 7 ADAM.ETS.SARIMA   1735375. -0.407
 8 X13.SARIMA.SEATS  1735862. -0.407
 9 TBATS             1814810. -0.471
10 SARIMA            1890119. -0.532
11 ETS               1944454. -0.576
```

```r
cspe_df <- map_dfc(previsions, ~ cumsum((obs - .x)^2)) |>
  mutate(Date = dates) |>
  pivot_longer(-Date, names_to = "Methode", values_to = "CSPE")

ggplot(cspe_df, aes(Date, CSPE, color = Methode)) +
  geom_line(linewidth = 1) +
  labs(title = "Erreur quadratique cumulée (CSPE) par modèle, 2020", x = "Temps", y = "CSPE") +
  theme_minimal(base_size = 12) +
  theme(legend.title = element_blank(), axis.text.x = element_text(angle = 45, hjust = 1))
```




Meilleur modèle selon le MSE : **SNaive** (MSE = 1 233 516). Le MSE du modèle naïf est de 1 233 516 ; 0 modèle(s) obtiennent un $R^2$OOS positif.

## 6 Test de Diebold-Mariano contre un AR(1)

Hypothèse alternative « less » : l'erreur du modèle testé est significativement plus faible que celle de l'AR(1). Avec seulement 12 observations de test, le test est utilisé avec `h = 1` (erreurs quadratiques) : un horizon `h = 12` ferait porter l'estimation de variance sur 11 retards pour 12 points, ce qui est dégénéré. Les p-values sont à lire avec prudence.

```
fitar1  <- Arima(train, order = c(1, 0, 0))
err_ar1 <- obs - as.numeric(forecast(fitar1, h = h)$mean)

dm <- map_dfr(names(previsions), function(m) {
  e <- obs - previsions[[m]]
  p <- tryCatch(dm.test(e, err_ar1, alternative = "less", h = 1, power = 2)$p.value,
                error = function(err) NA_real_)
  tibble(Modele = m, p_value_DM = p)
}) |> arrange(p_value_DM)
dm
```

```
# A tibble: 11 x 2
   Modele           p_value_DM
   <chr>                 <dbl>
 1 SNaive               0.0932
 2 ADAM.ETS             0.128
 3 Holt.Winters         0.133
 4 STS                  0.187
 5 SSARIMA              0.216
 6 STL                  0.217
 7 ADAM.ETS.SARIMA      0.219
 8 TBATS                0.234
 9 X13.SARIMA.SEATS     0.241
10 ETS                  0.274
11 SARIMA               0.282
```

## 7 Vérification sur la série brute (non corrigée)

La série `adj` n'a plus le choc de 2020. On recalcule le MSE contre la série brute pour voir si le classement change.

```r
obs_brut <- as.numeric(window(yy, start = c(2020, 1), end = c(2020, 12)))
tibble(Modele = names(previsions),
       MSE_brut = map_dbl(previsions, ~ mean((obs_brut - .x)^2))) |>
  arrange(MSE_brut)
```

```
# A tibble: 11 x 2
   Modele            MSE_brut
   <chr>                <dbl>
 1 SNaive           46820585.
 2 Holt.Winters     57455346.
 3 ADAM.ETS         58350067.
 4 TBATS            58903446.
 5 ETS              60227198.
 6 STS              60659743.
 7 STL              61577237.
 8 ADAM.ETS.SARIMA  61651378.
 9 SSARIMA          62340877.
10 X13.SARIMA.SEATS 62615772.
11 SARIMA           64427962.
```

# 8 Conclusion

La série présente une tendance baissière, une saisonnalité très marquée et stable, et deux chocs conjoncturels identifiés (RT 2012 en 2013, confinement en 2020). Les modèles sont comparés sur l'année 2020, atypique, ce qui limite la portée des classements : un seul horizon de 12 mois et 12 observations de test. Le meilleur modèle, le $R^2$OOS et les p-values de Diebold-Mariano figurent dans les tableaux ci-dessus et sont à lire à la lumière de ces limites.

Les critères d'information (AIC) de modèles estimés sur des échelles différentes (logarithme pour X13, niveaux pour les autres) ou de familles différentes (ETS, ARIMA) **ne sont pas directement comparables** ; la sélection repose donc ici sur la qualité de prévision hors échantillon.